LLM 能估算建筑外围护结构的隐含碳吗？误差分析、Prompt 设计与 LEED v5 启示

CEE226 第 8 组：George Zheng（jhzheng@stanford.edu）、Zixuan Zhao（zalex467@stanford.edu）、Heshan Chen（heshan@stanford.edu）、Fei Cheng（feicheng@stanford.edu）、Jamie Liu（jamiexyl@stanford.edu）。 本文属于项目 *Climate- and Use-Specific Embodied Impacts of Exterior Wall Design: A Comparative LCA and Implications for LEED v5 Embodied Carbon Credits*。

> English version: `report.md`。两个版本内容一致；最终 prompt 以英文原文为准（附录 A）。
>
> 状态：已完成。v1–v3 三版 prompt 在 292 栋建筑上各跑 3 轮，并做了 88 栋测试集的 held-out 评估（第 9 节）和 feature 研究（第 10 节）。最终 prompt 为 v3（附录 A 的 E 节）。 报告中的所有数字都可以用附录 B 的命令重新生成。

1. 摘要

本研究使用的 LLM 是 Claude Opus 5.5，以 Claude Code subagent 的方式运行，reasoning effort 设为 medium。研究对象是 CLF 统一化 WBLCA 数据集中的 292 栋建筑，模型拿到每栋楼的 48 个早期设计 feature，估算建筑外围护结构（**enclosure**）在摇篮到大门阶段（**A1–A3**）的隐含碳，单位为每 m² 楼面面积的 kgCO2e。

使用最简单的 prompt（v1，只靠模型自身知识）时，只有 **19.5%** 的估算落在参考 LCA 值的 ±20% 以内。RMSE 为 79.7 kgCO2e/m²，绝对百分比误差的中位数为 37.9%。

这些误差不是随机的。模型的问题有四个：

1. 把每栋楼都往一个"典型值"（约 50–60 kgCO2e/m²）上压；
2. 漏掉了数据里最大的单一材料来源：用 HFC 发泡剂生产的 XPS 保温板；
3. 没有给出围护面积时，模型自己估的面积偏小；
4. 对改造项目的工程范围判断有误。

模型最大的几个高估，多数是参考 LCA 本身不完整造成的。

我们根据这些分析写了 prompt v2，做了以下改动：

- 按数据集的分类方式定义 enclosure 的范围；
- 要求逐个构件计算；
- 点名高碳材料；
- 不许往典型值靠；
- 加入改造项目的规则；

- 要求额外给出一个最佳估计值。

prompt v2 的设计见第 6 节，全文见附录 A。

v2 让模型更稳定（CV 从 19.0% 降到 13.8%），压缩也减轻了（斜率从 0.46 升到 0.55），但准确率反而下降：命中率降到 15.1%（McNemar p = 0.085），APE 中位数升到 44.3%，偏差从 0.75 降到 0.67。原因有三点（第 7 节）：

- 模型提到了 XPS，却仍然默认屋面用 polyiso；
- 自下而上累加的构件强度偏低；
- 改造项目的规则把估算往下压了。

简单说，prompt 里的定性知识模型会照着复述，但不会用到数字里；要改变数字，必须在模型选数值的那一步直接给出具体数值。

prompt v3 正是这样做的（第 8 节）：

- 在选强度的那一步，给一张有外部来源的构件强度参考表；
- 写明 HFC-XPS 的工具建模习惯；
- 加入每 m² 围护面积的自检；
- 改写改造项目的规则，不再一味往下减。

v3 是最终 **prompt**。 在全部 292 栋上：

- 命中率 **25.0%**（v1 为 19.5%），RMSE 76.0，偏差 0.86，CV 12.5%。
- 相对 v1 的提升方向一致，但只是接近显著（McNemar p = 0.085，Wilcoxon p = 0.053）；相对 v2 的提升明显显著（p = 0.002）。
- enclosure 里 XPS 以外的部分已经没有偏差（0.99），给了围护面积的建筑也没有偏差（0.99）。
- 仍然存在的问题：高值端还在压缩（真实值 200 以上的楼比值只有 0.38），轻型围护被高估得更多，改造项目估得也不好。

Held-out 测试集（88 栋，分层切分；第 9 节）：

- v3 的命中率 26.1%（v1 为 20.5%），RMSE 69.2（v1 为 74.1），偏差 0.86（v1 为 0.75），CV 11.2%（v1 为 19.2%）。
- log 误差中位数和 v1 持平，这个样本量下 v1 与 v3 的差异不显著（McNemar p = 0.41）。
- 促成 v2、v3 的所有发现，只用 204 栋 dev 集也都能复现。

Feature 研究（第 10 节）。用 v3 时，只给 10 个早期设计 feature，准确率就和给全部 48 个一样；去掉 `mass_total` 或 LCA 事后字段也不会变差。不同 feature 集之间的差异，都没有超出同一 prompt 重复运行时的波动。限制准确率的是构造类型信息，而没有任何 feature 提供这一点。

对 **LEED v5** 的意义（第 11 节）。v3 的估算可以在方案阶段用于 MRp2 的热点筛查和围护方案比较，但精度不足以证明单栋建筑在 MRc2 中的减碳。enclosure 只占整楼 A–C 隐含碳的约 19%，所以围护减碳 30% 只相当于整楼约 6%。

把围护文献放进 **context**（第 8.2 节）。按 TA 的建议，我们把原来的整楼论文换成 4 份围护相关文献，prompt 仍用 v1，单跑一轮。结果反而更差：log 误差中位数增加 0.090（Wilcoxon $p < 0.001$），偏差从 0.72 降到 0.61。原因是这些文献描述的是现在的低碳产品，而参考 LCA 用的是评估当年的工具数据。v3 在所有指标上都优于这个条件。

气候与用途（第 2 节，proposal 的 RQ1）。用途对 enclosure 碳排影响显著（$p < 10^{-6}$）：多户住宅中位数 53.6，办公 87.2，交通枢纽 157.2 kgCO2e/m²。气候不显著（$p = 0.26$）：暖区 80.6，4 区 85.9，冷区 95.1。

热点一致性（第 11 节，MRp2）。v3 的回答在 94.6% 的情况下提到了参考 LCA 排第一的热点。随机提到同样多类别的期望只有 60.5%。但回答平均提到 6.7 个类别，不是排好序的前 3 名。

与 **proposal** 的范围差异。 11/3 check-in 后，我们改用课程的数据集方案：

- ground truth 改为 292 个真实项目的 enclosure A1–A3 GWP，不再自己建模 3 种墙体构造；单位为每 m² 楼面面积，只评估 GWP。
- RQ1（气候与用途）改为直接从数据分析。
- 知识条件：做了 innate、围护文献 domain 条件，以及两轮 prompt 修订；ontology 条件没有跑。为控制成本，每个条件跑 3 轮，文献条件和 feature 研究各 1 轮，而不是 proposal 写的 10 轮。
- LEED：热点一致性用基于提及的代理指标；MRc2 得分档一致性、LEED 版 ontology，以及成本、规范、性能等 key drivers 只做定性讨论或没有覆盖。

---

2. 数据与 ground truth

来源。 Benke et al. (2025)，*A Harmonized Dataset of High-Resolution Embodied Life Cycle Assessment Results for Buildings in North America*，Scientific Data（doi:10.1038/s41597-025-05216-0；数据在 figshare，CC BY 4.0）。`full_lca_results.xlsx` 共 927,950 行，每行对应一个项目在某个构件、某个生命周期阶段的一种材料，涵盖 292 个项目。

范围。 只保留 OmniClass 构件 `Shell - Enclosure` 和阶段 `A1-A3`（`GWP-calculation/sum_gwp.py`），剩下 55,807 行。

归一化。 GWP 总量除以楼面面积：新建项目用 `bldg_cfa`，49 个改造项目用 `bldg_renovated_gfa + bldg_added_gfa`。这和数据集自带的 `eci_a_to_c_cfa` 在 292 个项目上完全一致。这与 proposal 的功能单位（1 m² 外墙）不同：数据集里大多数项目没有外墙面积，而且它的 enclosure 还包括窗、门和屋面。

分布。 ground truth（`results/ground_truth.csv`）中位数 78.0 kgCO2e/m²，均值 95.6，范围 0.49–513.9，第 5–95 百分位为 10.5–255.7。Enclosure 约占全楼 A–C 总量的 19%（中位数）。

Enclosure 的碳来自哪些材料（占全部 enclosure A1–A3 GWP 的比例；`GWP-calculation/enclosure_breakdown.py`）：

材料类别	占比	其中最大的一项
保温	26.4%	XPS 占 enclosure 总量的 15.5%（占保温的 59%）
铝	22.0%	铝型材 17.4%
门窗与框	9.7%	铝店面 / 幕墙 7.3%
混凝土	8.9%	预制 3.4%
玻璃	7.8%	中空玻璃 IGU 4.0%
钢	6.6%	冷弯轻钢龙骨 2.9%
外饰面	6.5%	铝复合板 ACM 2.3%
砌体	5.0%	黏土砖 1.9%

这个数据集里 XPS 的排放因子是 **43.6 kgCO2e/kg**，而高密度矿棉是 1.2，玻璃棉 2.4，polyiso 3.1。这与用 HFC 发泡剂生产的 XPS 相符，当时的 LCA 工具（Tally、One Click LCA）就是这样建模的。292 个项目中有 149 个含有 XPS。

数据质量标记。 有 10 个新建项目（27、35、66、74、80、91、141、217、234、264）的 enclosure 清单里完全没有窗、玻璃、幕墙或店面的 **GWP**，但其中一些项目报告的 WWR 是 0.5–0.7。例如项目 74 的 WWR 为 0.65，真实值却只有 0.64 kgCO2e/m²。这更像是原始 LCA 模型不完整，而不是真的有不带玻璃的建筑。为了可比，这些项目保留在所有主要指标里，另外单独报告剔除它们之后的结果（"剔除不完整"）。

气候与用途（**proposal** 的 **RQ1**）。 只看新建、参考 LCA 完整的 233 个项目（其中 231 个有气候区），单位为 kgCO2e/m² 楼面面积（`analysis/climate_use.py`）：

用途	项目数	中位数
多户住宅	44	53.6
仓储	20	64.5
医疗	12	73.0
办公	41	87.2
教育	45	89.3
实验室	18	93.3
公共集会	27	95.8
公共安全	10	132.6
交通枢纽	9	157.2

- 用途的差异显著（Kruskal–Wallis $p = 2.7\times10^{-7}$）。
- 气候不显著（$p = 0.26$）：暖区（1–3）80.6，4 区 85.9，冷区（5–8）95.1。
- 按每 m² 楼面面积算，用途（通过玻璃比例和围护/楼面面积比）比气候（通过保温）更能决定 enclosure 碳排。

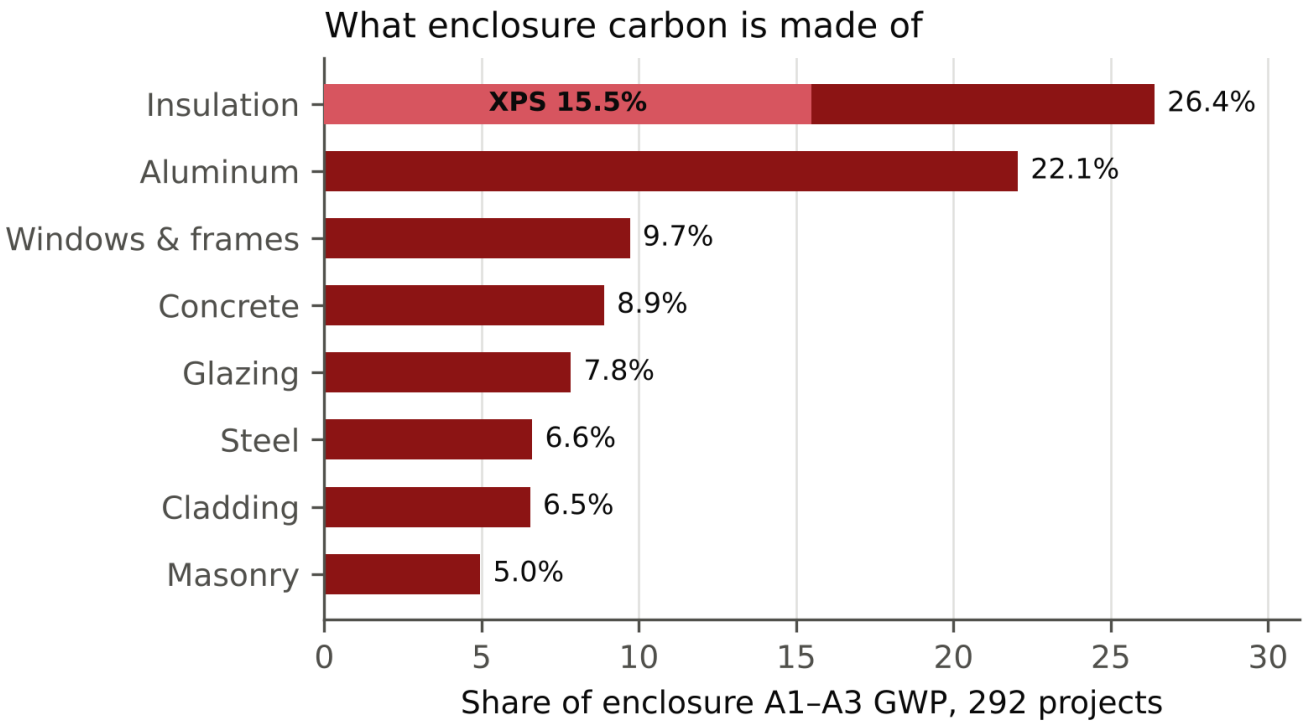


图 2.1：enclosure A1–A3 GWP 的材料构成（292 个项目）。XPS 单独占 15.5%。

3. LLM 实验设置

- 模型。 Claude Opus 5.5，以 Claude Code subagent 方式运行，reasoning effort 为 medium。课程参考代码用的是 Gemini API，本研究没有使用。另外用 Sonnet 5.5 做过一次试跑（49 栋、1 轮），只用来测试流程。
- 输入。 `references/buildings_metadata_LLM.xlsx` 的全部 48 个 feature（算上 `project_index` 共 49 列），再加 feature 说明表。不提供论文、benchmark 表或 ontology，即"只靠模型自身知识"的条件。
- 流程。 每版 prompt 跑 292 栋 × 3 轮 = 876 个估算。每个 subagent 负责一个任务文件，内容是共享上下文加 48–49 栋楼。每一轮用固定种子（1000 + 轮次编号）打乱楼的顺序，再分成 6 组。各版 prompt 使用完全相同的分组，因此可以逐栋楼配对比较。
- 隔离。 subagent 只能读自己的任务文件、写自己的答案文件，不能联网、不能运行代码、不能打开其他文件，所以看不到 ground truth。和单独调用 API 不同，同一个任务文件里的楼共享一个上下文。我们在指令里要求模型独立判断每一栋楼，并且每一轮重新打乱顺序，让每栋楼的"邻居"轮轮不同。
- 解析。 沿用课程的解析器（`RANGE_kgCO2e_per_m2: low - high`，取最后一个匹配），只改了一处：允许下限为 0。v1 中有 11 个改造或租户装修项目的回答下限为 0（例如"0 – 5"），这些项目的真实值是 2.6–26 kgCO2e/m²，其中 10 个低于 14。如果用课程原来的解析器，丢掉的恰恰是这些低碳项目。prompt v2 另外增加了一行 `BEST_kgCO2e_per_m2`。
- 指标。 每栋楼的估算值取各轮区间中点的平均。准确率指标包括：±20% 命中率（真实值落在估算值 ±20% 以内，附 Wilson 95% 置信区间）、RMSE、MAE、MAPE、APE 中位数，以及估算/真实值的几何平均（衡量偏差）。一致性指标是各轮之间的变异系数 CV。结果还按气候区和建筑用途分组（对应

RQ1）。所用脚本：`LLM-data-cleaning.py`、`make_fig1_bands.py`、`summarize_run.py`、`analysis/error_analysis.py`。

4. Baseline 结果（prompt v1）

876 个答案全部解析成功（`results/20261104_baseline-innate/`）。

子集	n	±20% 命中率	RMSE	APE 中位数	估算/真实（几何平均）	各轮 CV
全部项目	292	19.5%（CI 15.4–24.5%）	79.7	37.9%	0.75	19.0%
新建项目	243	18.9%	77.4	37.5%	0.76	17.3%
剔除 10 个不完整 ground truth	282	20.2%	80.5	37.3%	0.72	19.1%

63% 的楼真实值高于 ±20% 区间（被低估），17.5% 低于区间（被高估）。

图：`results/20261104_baseline-innate/figures/fig1_bands_sorted.png`（区间图）、`fig2_estimate_vs_truth.png`（散点图）、`fig3_ratio_by_group.png`（按气候区和用途分组）。

这些结果不能和课程上整栋楼 A–C 的结果（Gemini，命中率 34–46%）直接比较，因为研究范围、模型和 ground truth 都不一样。

5. 误差分析：模型为什么低估、为什么高估

数据来源：`analysis/error_analysis_20261104_baseline-innate.md`，以及逐材料的 ground truth 和 876 段推理文字。

5.1 主要模式是"压缩"，而不是整体一致地低估

真实值（kgCO2e/m²）	n	估算/真实（中位数）
< 25	36	1.58（高估）
25–50	43	1.09
50–100	114	0.76
100–200	72	0.54
> 200	27	0.28

- 估算对真实值在 log-log 坐标下的回归斜率只有 **0.46**：真实值翻一倍，估算只增加约 37%。
- 估算值在各楼之间的标准差，只有真实值标准差的 0.39。
- 估算范围是 1.7–168 kgCO2e/m²，真实值范围是 0.5–514。
- 区间中点集中在 42–62 kgCO2e/m²。

- 误差最大的 20 栋楼贡献了 68% 的平方误差，而且这 20 栋全部是低估。

模型对几何信息的依赖超出了数据本身的支持。围护面积与楼面面积之比，和 log 估算的相关是 0.62，和 log 真实值只有 0.39；单位面积质量的对应数字是 0.68 对 0.53。模型抓不住的是"每 m^2 围护面积的碳强度"：真实值里这个强度从 19 到 278 $kgCO2e/m^2$ 围护（第 5–95 百分位），估算值里只有 20 到 144。仅这一项就和 log 误差有 −0.79 的相关。这个强度由材料和构造选择决定，而 **48** 个 **feature** 里没有一个描述外墙构造。

5.2 为什么低估

1. **HFC** 发泡的 **XPS** 是最大的单一原因，而模型完全没考虑。
    - XPS 占全部 enclosure 碳排的 15.5%，出现在 149 个项目里。但模型只在 0.6% 的回答里提到 XPS（在含 XPS 的项目中是 0.7%），提到 HFC 发泡剂的一次都没有。
    - 含 XPS 的项目估算/真实中位数为 0.67，不含的为 0.80；XPS 占真实值 30% 以上的项目只有 0.59。
    - 把 XPS 从真实值里扣掉，估算/(真实 − XPS) 的中位数从 0.72 升到 0.84。系统性低估大约有一半来自 **XPS**。
    - 例子：project-198（酒店，4C 区）真实值 361.8，其中 XPS 占 325.9。模型的计算假设屋面约 30 $kgCO2e/m^2$，估算只有 22–36。
2. 气候区差异也来自 **XPS**。
    - 寒冷区（5–8 区）估算/真实中位数 0.65，温暖区（1–3 区）为 0.77。
    - 5A、5B 区有 65–68% 的项目含 XPS（比值 0.64–0.65），3B、3C 区只有 26–33%（比值 0.83–0.86）。寒冷地区保温更厚，HFC-XPS 层的分量就更重。
    - 所以气候区的差异本质上是保温材料的效应，不能说明模型忽视了气候。
3. 没有给围护面积时，模型自己估的面积偏小。
    - 160 个项目给了 `bldg_therm_env_area`。给了时比值中位数为 0.81，没给时为 0.65。
    - 高层建筑差距最大：21 层以上没给面积时为 0.24，给了时为 0.67。
    - 例子：project-198 是 2–5 层的建筑，模型假设围护/楼面面积比约为 0.6，而数据中 2–5 层建筑的中位数是 1.07，这可能是因为数据集的热工围护面积包含了首层底板。
4. 铝幕墙的分布尾巴很长。
    - 铝占总量的 22%，单个项目仅幕墙一项就能达到每 m^2 楼面 300 $kgCO2e$。
    - 例子：project-137（办公，小型改造）真实值 513.9，其中 302 来自新换的幕墙。模型推断"小改造会保留原有幕墙"，只估了 35。
5. 改造项目的范围估得太窄。
    - 60% 的大型改造被低估，租户装修的比值低到 0.24。模型倾向于假设原有围护被保留。
    - 能反映新做了多少材料的 feature 是"单位面积 `mass_total`"（和真实值相关 0.53），但只有 8.6% 的回答用到了它。

6. **v1** 写的范围比数据集里的 **enclosure** 窄。
    - 统一化数据里，有 11% 的 enclosure GWP 在原始软件中被标为 "Superstructure"（主要是屋面 XPS/PIR 和屋面防水），9.6% 标为 "Undefined"。
    - 外墙龙骨、衬板、外墙内侧石膏板、楼板边缘和地下保温也都算在 enclosure 里。
    - v1 的范围描述（"外墙与饰面、窗、幕墙、门、屋面及其保温"）把这些都留给模型自己判断。

5.3 为什么高估

1. 参考 **LCA** 不完整。 那 10 个被标记、完全没有门窗玻璃 GWP 的新建项目，估算/真实中位数为 3.09。模型对它们的估算是合理建筑应有的数值，不合理的是参考值。例如 project-74 的 WWR 为 0.65，模型估 62，真实值只有 0.64。
2. 新做的围护工程很少。 真实值低于 25 kgCO2e/m² 的项目（比值中位数 1.58）大多是租户装修和小型改造，而 feature 里没有信息说明到底换了多少围护。

5.4 已排除的因素

R 值、WWR、建筑规模、竣工年份和 `lca_ec_reductions` 与误差的相关都很弱（|r| ≤ 0.26）。各轮之间的一致性尚可：CV 中位数 17%，均值 19%。

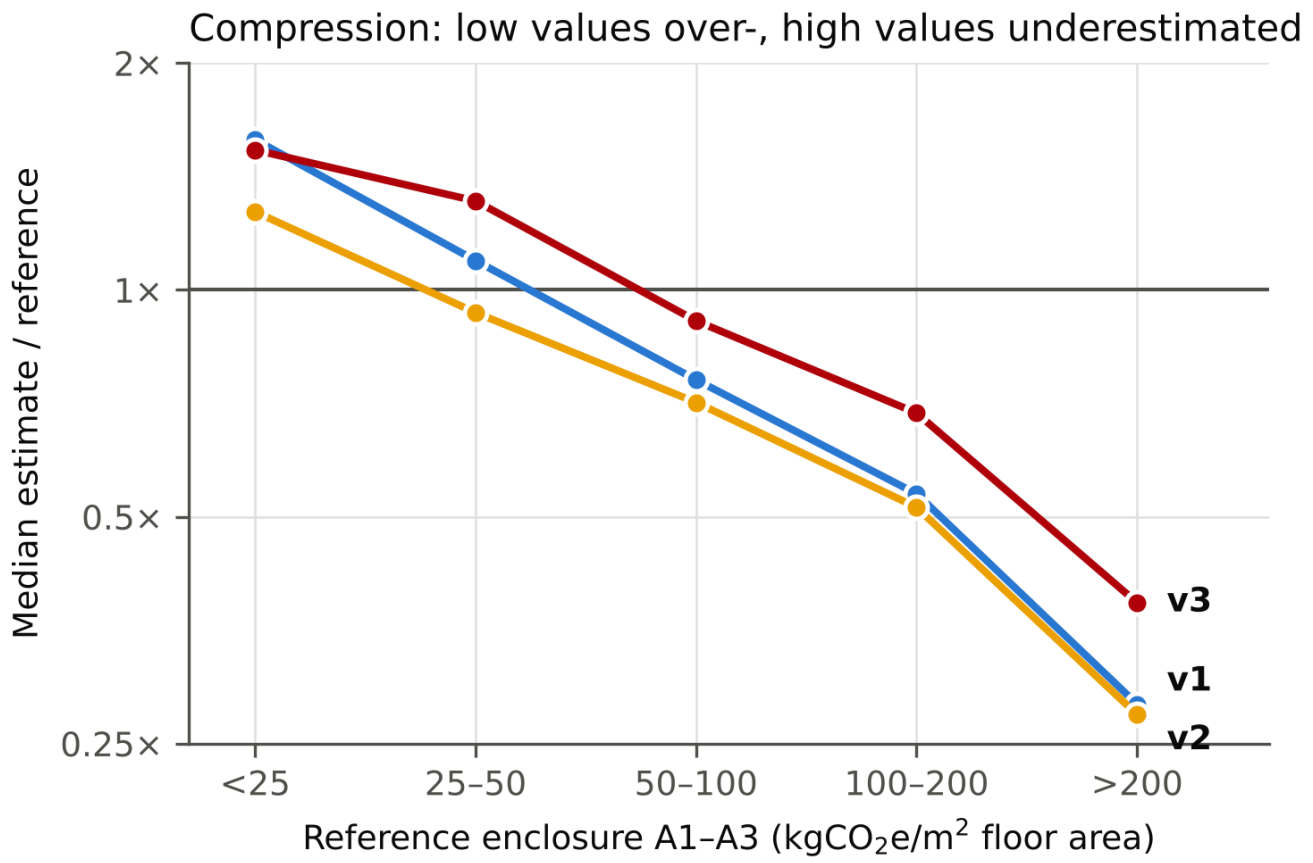


图 5.1：按参考值分档的估算/参考比值中位数，三版 prompt 都有压缩

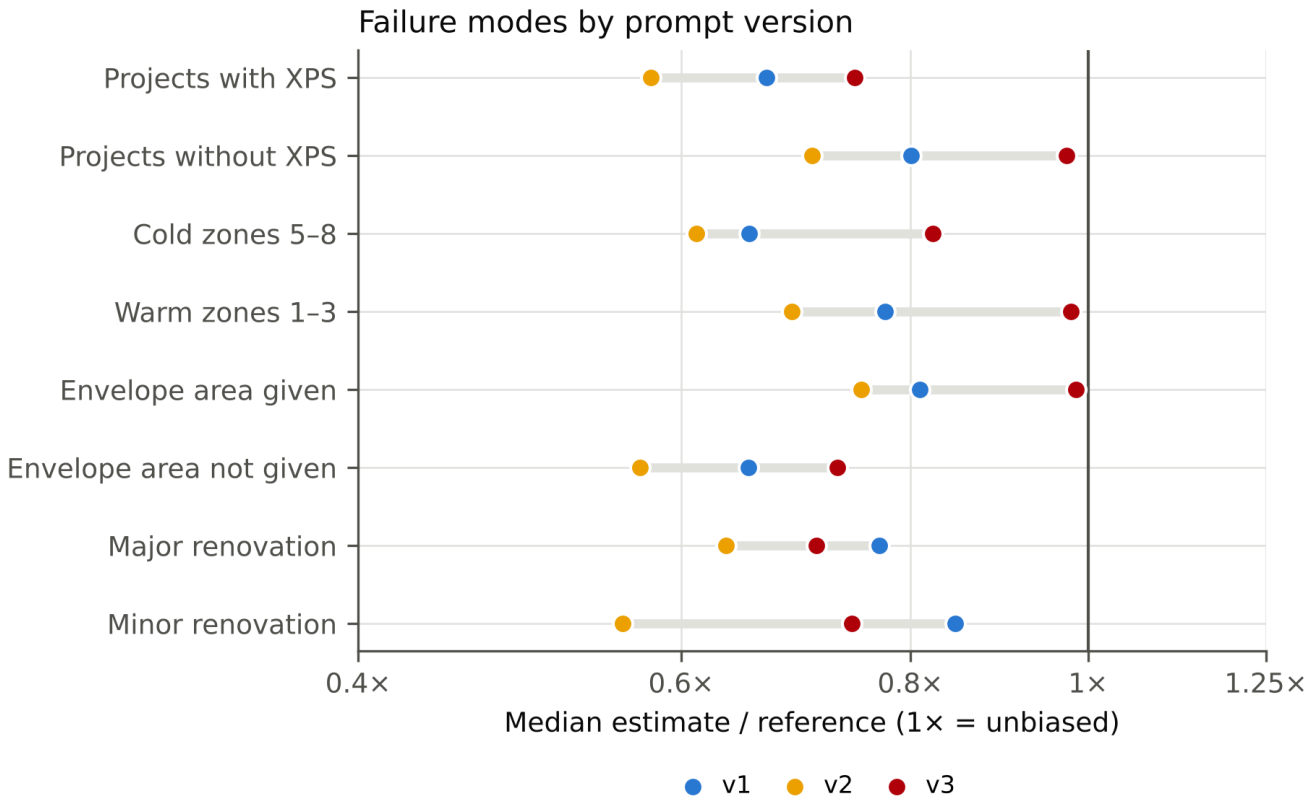


图 5.2：各失效模式对应的子组，按 prompt 版本

6. Prompt v2

v2 的任务文本替换了 v1。system prompt 和共享上下文（feature 说明表）不变，模型、effort、feature、种子和分组也都不变。全文见附录 A 的 D 节。

Baseline 发现（第 **5** 节）	**Prompt v2** 的改动
5.2.6：范围比数据集的 enclosure 窄	按数据集写明范围：完整外墙构造（饰面、龙骨、衬板、保温、隔汽层、内侧石膏板）、门窗玻璃、结构板以上的屋面构造、楼板边缘和地下保温；并明确列出排除项
5.1：靠几何、强度靠猜；5.2.3：围护面积估小	规定计算方法：(1) 用 `bldg_therm_env_area` 取面积，或自行估算并写出围护/楼面面积比；(2) 选构造，写出保温类型和厚度；(3) 给每个构件的单位面积强度；(4) 加总后除以楼面面积
5.2.1–5.2.2：漏掉 XPS、气候差异；5.2.4：幕墙长尾	点名高碳材料：HFC 发泡 XPS（按单位热阻计，GWP 约为矿棉、玻璃棉、polyiso 的 10 倍以上）、铝幕墙（约 100–200 kgCO2e/m² 立面）、中空玻璃、预制混凝土、砌体
5.1：往典型值压缩	"不要把估算往典型建筑靠"，并点出两端（> 200 和 < 10 kgCO2e/m²）
5.2.5、5.3.2：改造项目	只计新材料；用 `bldg_proj_type`、`lca_phys_scope` 和单位面积 `mass_total` 判断工程量
用宽区间的中点当估算值（区间相对宽度中位数 0.75）	在 `RANGE` 行之前增加 `BEST_kgCO2e_per_m2` 行（`RANGE` 仍放在最后，课程解析器照常可用）

材料说法的出处。 关于 XPS 的说法是定性的，有外部资料支持：

- 加拿大 Alberta 的 *PERSIST* 保温指南指出，在常见板状保温材料中 XPS 的隐含 GWP 最高，原因是 HFC 发泡剂（alberta.ca）。
- 佛蒙特州 R408 隐含碳草案表中，XPS（HFC）为 55.5，矿棉毡为 1.7，polyiso 板为 4.1（publicservice.vermont.gov）。

幕墙的数值区间依据铝框幕墙 EPD，其 A1–A3 为 117–134 kgCO2e/m²（One Click LCA EPD 库）。Arup 的立面研究给出的是 160–520 kgCO2e/m²，但系统边界更宽，包括 A1–A5、B4 和 C（Arup）。

关于拟合本数据集的问题。 促成 v2 的误差分析用的就是评估 v2 的这 292 栋楼。本项目的目标是一个能用到其他项目上的 prompt，而不是针对这 292 栋做校准。因此 v2 只写了在本数据集以外也成立的内容：范围定义、计算步骤和有文献支持的材料事实，不包含中位数、拟合系数等数据集统计量。干净的检验需要换一个数据集做 held-out 评估（第 9 节）。

---

7. 结果：**prompt v2** 对比 **v1**

v2 的 876 个答案全部解析成功（`results/20261104_prompt-v2/`），使用和 v1 相同的楼、种子和分组。

子集	**Prompt**	**±20%** 命中率	**RMSE**	**APE** 中位数	**MAPE**	估算/真实（几何平均）	各轮 **CV**
全部项目（292）	v1	**19.5%**	**79.7**	**37.9%**	96.0%	**0.75**	19.0%
	v2 中点	15.1%	81.0	44.3%	**83.0%**	0.67	**13.8%**
	v2 BEST	14.4%	83.2	49.4%	81.4%	0.59	13.8%
新建项目（243）	v1	18.9%	77.4	37.5%	93.4%	0.76	17.3%
	v2 中点	16.5%	79.8	44.2%	81.7%	0.70	11.8%
剔除 10 个不完整（282）	v1	20.2%	80.5	37.3%	57.8%	0.72	19.1%
	v2 中点	15.6%	81.9	43.9%	57.7%	0.64	13.5%

配对检验（同样的 **292** 栋）。

- v2 的误差更大（对 |log(估算/真实)| 做 Wilcoxon 符号秩检验，$p < 0.0001$），只在 34% 的楼上比 v1 更接近真实值。
- 命中率的下降不显著（McNemar $p = 0.085$）：31 栋只有 v1 命中，18 栋只有 v2 命中。

Prompt v2 没有提高准确率。 它提高了一致性、减轻了压缩，但让低估更严重。各项诊断的并列对比见 `analysis/error_analysis_20261104_baseline-innate_vs_20261104_prompt-v2.md`。

误差模式（第 **5** 节）	**v1**	**v2**	**v2** 的效果
压缩：log-log 斜率（1 = 无压缩）	0.46	0.55	变好
压缩：估算标准差 / 真实值标准差	0.39	0.47	变好
低值端高估（真实值 < 25）：估算/真实	1.58	1.27	变好
一致性：各轮 CV 均值	19.0%	13.8%	变好
含 XPS 的项目中提到 XPS 的比例	0.7%	39.6%	模型开始提到它
含 XPS 的项目：估算/真实	0.67	0.58	变差
没给围护面积：估算/真实	0.65	0.57	变差
寒冷区 5–8 / 温暖区 1–3：估算/真实	0.65 / 0.77	0.61 / 0.69	变差（差距相近）
小型改造 / 大型改造：估算/真实	0.85 / 0.77	0.56 / 0.63	变差
被标记的不完整 ground truth：估算/真实	3.09	3.07	不变（不是 LLM 的错）

7.1 **v2** 为什么低估得更多

1. 知道一个事实，不等于会用它。
    - v2 的回答提到 XPS 的频率是原来的 50 倍，但其中 89% 仍然默认屋面保温用 **polyiso**。
    - XPS 大多被放在地下或楼板边缘：这种语境下出现 274 次，在屋面语境下只有 114 次。
    - 而在参考 LCA 里，大部分 XPS 位于屋面或楼板层（XPS GWP 中有 54.5% 在 Tally 中被标为 "Superstructure"）。模型的假设符合常见施工做法，却不符合这些 LCA 模型的搭建方式。
    - 结果，v2 计算里屋面强度的中位数是 **35 kgCO2e/m²**（四分位距 30–40），含 XPS 的项目不但没改善，反而更差了。
2. 自下而上的构件强度偏低。
    - v2 计算中各构件强度的中位数：不透明墙 80 kgCO2e/m²（四分位距 65–110），屋面 35，玻璃和幕墙 145（四分位距 126–320）。
    - 换算成每 m² 围护面积（有围护面积数据的 160 个项目），v2 的中位数为 66.8，v1 为 72.4，真实值为 **86.7**。
    - 根据早期信息逐项计算，会漏掉参考 LCA 里包含的很多零碎项目。prompt 里给的幕墙区间（100–200 kgCO2e/m²）还被模型当成了默认值（中位数 145）。
3. 改造项目的规则起了反作用。"只计新的围护材料"让小型改造从 0.85 降到 0.56，大型改造从 0.77 降到 0.63。对一个本来就低估的模型，一条"往下减"的规则只会让情况更糟。
4. **BEST** 低于区间中点（中位数为中点的 0.93 倍）。模型的不确定性是右偏的，所以它自报的最佳估计在这里反而更不准。

7.2 对 **prompt** 设计的启示

这几条启示不只适用于本数据集：

- 结构化的分步方法能让模型更稳定（CV 降低 27%），也更少往典型值靠。但它同时把模型对各构件的先验暴露了出来：如果这些先验有偏差，分步结构会把偏差直接带进总数。

- 定性知识（"XPS 大约高 10 倍"）会被模型在推理里复述，但不会改变数字。要改变估算，prompt 必须在模型选数值的那一步给出具体数值，并说明适用条件（例如 LCA 工具很可能是按哪种保温建模的）。
- 往下减的指令（排除项、"只计新材料"）要和"应该包含什么"配套给出，否则会放大已有的低估。
- 报告时用区间中点，不要用模型自报的最佳值。

---

8. Prompt v3

v3 保留了 v2 中有效的部分：范围定义、分步方法和"不要往典型值靠"。第 7 节证明无效的部分则做了修改。全文见附录 A 的 E 节。

v2 的结果（第 **7.1** 节）	**Prompt v3** 的改动
提到了 XPS 却没用上；默认 polyiso 屋面	第 2 步写明工具建模习惯：这一时期的整楼 LCA 模型（Tally、One Click LCA）常把屋面和地下保温按 HFC-XPS 建模。保温类型不明确时，区间必须包含这种情况，寒冷地区尤其要考虑
自下而上的构件强度偏低	第 3 步给出每 m² 构件的 A1–A3 强度参考表：8 类外墙、3 类门窗幕墙、按保温类型分的屋面构造（HFC-XPS：只计生产阶段为 85–110，把发泡剂排放计入产品时最高 335–410）、每 m²·RSI 的保温强度、每 kg 铝的排放。同时告诉模型完整构造包括龙骨、连接件、隔汽层、密封胶和收边，除非构造明显很简单，不要低于区间下限
没有对总数做自检	第 4 步：把总数换算成每 m² 围护面积。对于常规外墙、30–40% 玻璃比例的新建项目，如果低于约 50 kgCO2e/m² 围护，说明漏了某个构件或高碳选项
区间没包含高碳的可能	第 5 步：区间必须包含合理的高碳选项（以中点作为估算值）
改造项目的规则往下减	第 6 步改写为：改造项目常常包含大量新的围护工程（换外饰面、换幕墙或窗、重做屋面），除非数据显示原有围护被保留，否则不要这样假设
BEST 不如中点准	改回只输出一行 `RANGE`

来源。 参考数值由另一个能联网的 research subagent 整理，写在 `references/envelope_intensities_sources.md` 里，附有来源链接、系统边界和单位换算。来源包括：

- CLF 北美材料基准（2023 和 2025）；
- PCI 预制混凝土行业平均 EPD（2025）；
- Kawneer 的幕墙、店面和窗 EPD（2021）；
- RDH Building Science 的外墙构造研究；
- UBC 的门窗研究；
- SPRI、NAIMA、AEC 的行业 EPD（通过 CLF 基准引用）；
- Arup/Saint-Gobain 的立面研究。

研究要求中明确排除了 Benke et al. 数据集及其衍生内容。subagent 还主动排除了 CLF WBLCA Benchmark v2 的结果，因为它们很可能和 ground truth 共用源模型。部分外墙数值是 subagent 自己把各构件加总得到的，在那个文件里标为不确定。第 4 步中"每 m² 围护低于约 50"这个阈值，是我们从这些构件区间推导出来的，不是已发表的基准值。

8.1 结果：**prompt v3** 对比 **v2** 和 **v1**

v3 的 876 个答案全部解析成功（`results/20261104_prompt-v3/`）。模型、effort、feature、楼、种子和分组都和 v1、v2 相同。

第 2 轮运行中，容器重启打断了 6 个 subagent，当时这一轮 292 个答案只完成了 130 个。其余 162 栋由 6 个续跑 subagent 完成，prompt 相同，任务文件里只包含缺失的楼（`subagent_runs.py resume`，已记录在 manifest 中）。因此这 162 栋共享上下文时的"邻居"和原计划不同。

子集	**Prompt**	**±20%** 命中率	**RMSE**	**APE** 中位数	估算/真实（几何平均）	各轮 **CV**
全部项目（292）	v1	19.5%（15.4–24.5）	79.7	**37.9%**	0.75	19.0%
	v2	15.1%（11.4–19.6）	81.0	44.3%	0.67	13.8%
	v3	**25.0%**（**20.4–30.3**）	**76.0**	40.0%	**0.86**	**12.5%**
新建项目（243）	v1	18.9%	77.4	37.5%	0.76	17.3%
	v3	**26.3%**	**74.1**	38.0%	**0.91**	**10.9%**
剔除 10 个不完整（282）	v1	20.2%	80.5	37.3%	0.72	19.1%
	v3	**25.9%**	**76.5**	37.4%	**0.83**	**12.6%**

配对检验（同样的 **292** 栋）。

- **v3** 对 **v1**：46 栋只有 v3 命中，30 栋只有 v1 命中（McNemar p = 0.085）。|log(估算/真实)| 的中位数从 0.456 降到 0.426（Wilcoxon p = 0.053），v3 在 57% 的楼上更接近真实值。在 3 轮 × 292 栋的规模下，提升方向一致，但只是接近显著。
- **v3** 对 **v2**：提升显著（McNemar p = 0.002；Wilcoxon p < 0.0001），v3 在 66% 的楼上更接近真实值。
- **APE** 中位数：v3 的 log 误差更低，APE 中位数却比 v1 略差（40.0% 对 37.9%）。原因是 v3 把估算整体往上调了，而 APE 对高估的惩罚比对低估重。
- 高估和低估的比例：v1 下 58% 的楼低估超过 20%、18% 高估超过 20%；v3 下这两个比例变为 46% 和 29%。偏差变小了，误差的分布也更均衡。

误差模式（第 **5** 节）	**v1**	**v2**	**v3**
整体偏差：估算/真实（几何平均）	0.75	0.67	**0.86**
压缩：log-log 斜率（1 = 无压缩）	0.46	0.55	**0.59**
压缩：估算标准差 / 真实值标准差	0.39	0.47	**0.63**
真实值 50–100：估算/真实	0.76	0.71	**0.91**
真实值 100–200 / > 200：估算/真实	0.54 / 0.28	0.51 / 0.27	**0.69 / 0.38**
真实值 < 25 / 25–50：估算/真实	1.58 / 1.09	**1.27 / 0.93**	1.53 / 1.31
含 XPS 的项目中提到 XPS 的比例	0.7%	39.6%	**96.0%**
提到 HFC / 发泡剂的比例	0%	4%	**88%**
含 XPS 的项目：估算/真实	0.67	0.58	**0.75**
估算/(真实 − XPS)	0.84	0.77	**0.99**
寒冷区 5–8 / 温暖区 1–3：估算/真实	0.65 / 0.77	0.61 / 0.69	**0.82 / 0.98**
给了 / 没给围护面积：估算/真实	0.81 / 0.65	0.75 / 0.57	**0.99 / 0.73**
小型 / 大型改造：估算/真实	**0.85 / 0.77**	0.56 / 0.63	0.74 / 0.71
租户装修：估算/真实	0.24	0.26	0.26

有效的部分。

- 在选数值的那一步给出具体数值。 在含 XPS 的项目上，96% 的回答提到了 XPS（以及它的发泡剂）。
- **XPS** 以外的 **enclosure** 部分已经没有偏差：估算/(真实 − XPS) 从 0.84 升到 0.99。
- 给了围护面积时，估算整体没有偏差（0.99）。修正自下而上总数偏低的，是构件参考值和每 m² 围护的自检这两项。
- 温暖区的气候差距消除了：温暖区现在是 0.98。寒冷区（0.82）仍然低估，原因是厚的 HFC-XPS 层：XPS 占真实值 30% 以上的项目仍只有 0.61。

尚未解决的部分。

1. 压缩减轻了，但没有消除（斜率 0.59）。真实值 200 以上的楼仍只有 0.38，它们的极端数值（例如幕墙或 XPS 超过 300 kgCO2e/m²）无法从 feature 推出来。
2. 低碳建筑现在被高估得更多。 真实值 25–50 那一档，比值从 1.09 升到 1.31。"不要低于区间下限"和每 m² 围护的自检，会把轻型围护往上推，这是纠正低估付出的代价。
3. 没给围护面积时仍然低估（0.73）。
4. 改造项目仍不如 **v1**。 比 v2 有所恢复，但没回到 v1 的水平；租户装修仍停在 0.26。

最终 **prompt**。 在命中率、RMSE、偏差、log 误差和一致性上，v3 都是三版中最好的，因此作为本研究的最终 prompt（附录 A 的 E 节）。

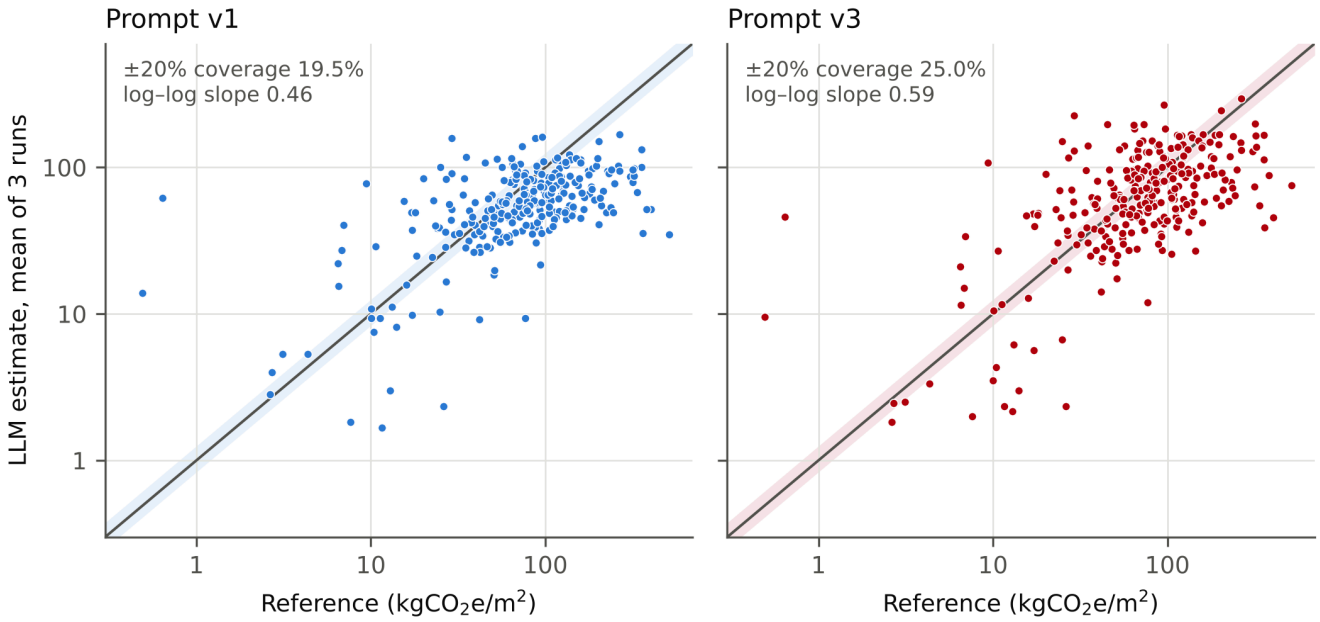


图 8.1：v1 与 v3 的估算对参考值（1:1 线和 ±20% 带）

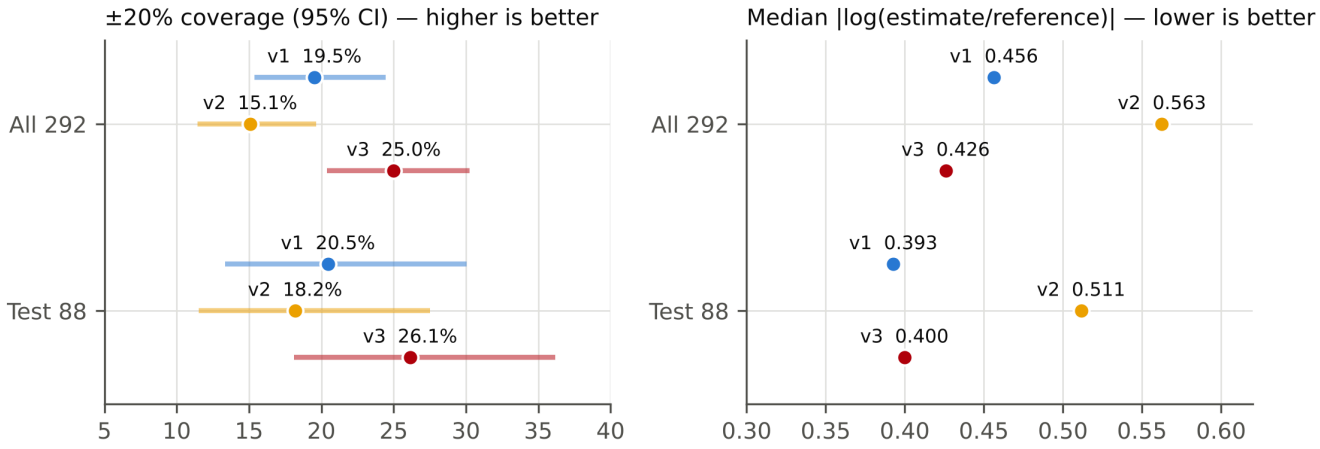


图 8.2：全部 292 栋和 88 栋测试集上的命中率（95% CI）与 log 误差中位数

8.2 对照：把围护文献放进 **context**（**domain knowledge**）

课程框架里，domain knowledge 的做法是把参考文献放进 context。按 TA 在 check-in 上的建议，我们把原来的整楼论文换成 4 份围护相关文献：

- RDH Building Science 的墙体构造 LCA（2025）；
- CLF 2023 北美材料基准；
- Arup/Saint-Gobain 的幕墙与玻璃研究；
- UBC 的门窗隐含碳研究（2022）。

每份截取 30k 字符，和课程流程一样。任务文本保持 v1 不变，所以和 baseline 的唯一区别就是这些文献。这个条件只跑了一轮，与 v1、v3 的第 0 轮逐栋配对比较（分块和顺序相同；`analysis/domain_study.py`）。

条件	命中率	**log** 误差中位数	偏差	**RMSE**
v1（innate）	17.8%	0.519	0.72	81.2
v1 + 文献	15.8%	0.609	0.61	85.3
v3（最终 prompt）	24.3%	0.461	0.86	77.8

结果：文献让估算变差了。

- log 误差中位数增加 0.090（Wilcoxon $p < 0.001$），偏差从 0.72 降到 0.61，只有 35% 的楼变得更准。命中率下降 2.1 个百分点，不显著（$p = 0.48$）。
- v3 在所有指标上都优于文献条件（命中率 +8.6 个百分点，McNemar $p = 0.011$；log 误差 −0.148，$p < 0.001$）。

原因。 模型确实读了文献：22% 的回答引用了它们，多半是用来支持区间的下限（"per RDH"，"CLF baselines support the lower end"）。但这些文献描述的是现在的低碳产品：HFO 发泡的喷涂泡沫、近年的 EPD 基准、现代玻璃。而参考 LCA 用的是评估当年的工具数据。

- 回答里提到 XPS 的比例从 0.7% 降到 0；
- 有 XPS 的项目，比值从 0.64 降到 0.50；
- 没有 XPS 的项目，也从 0.78 降到 0.68。

和 v2 一样，这说明给更多领域文字并不能纠正盲点；如果文字描述的产品年代和参考模型不同，反而会加重盲点。v3 有效的是一张有来源的强度表，加上一句关于建模习惯的明确说明。

---

9. Held-out 评估

没有合适的外部数据集。 我们找过结构相同的独立数据集（北美建筑、按构件分的 enclosure A1–A3 结果、加上早期设计 feature），没有找到：

- CLF WBLCA Benchmark v2 的结果很可能和 Benke et al. 数据集共用源模型。
- 开放的 CarbEnMats / Global Buildings Database（Zenodo）有 1,200 多个案例，但只有 172 个给出了 envelope 的 A1–A3 数值，而且全在欧洲（比利时 105、荷兰 47、芬兰 19、英国 1）。它的 "envelope" 只包括开口和饰面，外墙和屋面算在结构里。这 172 栋的围护面积、WWR 和 U 值全是空的，只有 12% 有层数。我们检查过数据，决定不做映射。
- Mendeley 的 "virtual building database"（链接）是合成数据。

因此，我们从本数据集中留出一部分作为测试集。

切分方法。 `analysis/make_split.py`（种子 226）把 30% 的项目分到测试集（88 个），70% 分到 dev 集（204 个），只按输入 feature 分层：新建/改造 × 气候组（寒冷区 5–8、4 区、温暖区 1–3、其他）。两组的真实值中位数相近（78.8 / 74.6 kgCO2e/m²）。测试集中含 XPS 的项目较少（43%，dev 为 54%），10 个被标记的不完整 ground truth 中有 2 个在测试集。

切分是在 **v1–v3** 都跑完之后才定的。 因此，设计 v2 和 v3 时做的误差分析，已经看过包括测试集在内的全部 292 栋的整体规律。为了检验这一点没有左右 prompt 设计，我们只用 dev 集重新做了全部诊断（`analysis/error_analysis_…_dev.md`）。用来修改 prompt 的每一项发现在 dev 集上都能复现：

促成 **prompt** 修改的发现	全部 **292** 栋	只用 **dev**（**204** 栋）
v1 压缩：log-log 斜率	0.46	0.44
v1 真实值 > 200 / < 25 时的估算/真实	0.28 / 1.58	0.28 / 1.59
XPS 占 enclosure A1–A3 GWP 的比例	15.5%	14.7%
v1 含 / 不含 XPS 的估算/真实	0.67 对 0.80	0.66 对 0.77
v1 估算/(真实 − XPS)	0.84	0.80
v1 寒冷区 / 温暖区	0.65 对 0.77	0.64 对 0.71
v1 给了 / 没给围护面积	0.81 对 0.65	0.79 对 0.65
v1 提到 XPS 的回答比例	0.6%	0.5%
被标记的不完整 ground truth：v1 估算/真实	3.09	3.09
v2 回答中屋面用 polyiso 的比例；屋面强度中位数	89%；35	89%；35
v2 每 m² 围护的估算 vs 真实值	66.8 对 86.7	68.1 对 85.5
v2 小型改造的估算/真实（v1 → v2）	0.85 → 0.56	0.79 → 0.40

也就是说，只用 dev 集也会得出同样的 prompt 修改。两版 prompt 都不包含任何单栋楼的信息或从本数据集算出的统计量，v3 的参考数值全部来自外部 EPD 和基准。

测试集结果（**88** 栋，从未用来挑选 **prompt**）：`analysis/compare_…md`

Prompt	**±20%** 命中率（**95% CI**）	**RMSE**	**APE** 中位数	**log** 误差绝对值中位数	估算/真实（几何平均）	各轮 **CV**
v1	20.5%（13.3–30.0）	74.1	**36.4%**	**0.393**	0.75	19.2%
v2	18.2%（11.5–27.5）	75.7	43.4%	0.511	0.66	15.2%
v3	**26.1%**（**18.1–36.2**）	**69.2**	37.0%	0.400	**0.86**	**11.2%**

测试集配对	只有前者命中 / 只有后者命中	**McNemar p**	**log** 误差绝对值（**Wilcoxon p**）	后者更接近的比例
v1 对 v3	9 / 14	0.41	0.393 → 0.400（p = 0.38）	55%
v2 对 v3	11 / 18	0.27	0.511 → 0.400（p = 0.002）	62%
v1 对 v2	9 / 7	0.80	0.393 → 0.511（p = 0.0002）	34%

怎么解读 **held-out** 结果。

- 在测试集上，v3 的命中率提高 5.6 个百分点，RMSE 降低 4.9 kgCO2e/m²，偏差从 0.75 改善到 0.86，一致性从 CV 19.2% 改善到 11.2%。
- 但它的典型误差（log 误差绝对值中位数）和 v1 持平；在 n = 88 时，v1 与 v3 的各项差异都不显著。
- v3 明显优于 v2（Wilcoxon p = 0.002），v2 比 v1 差这一点在测试集上同样复现（p = 0.0002）。

- 测试集中含 XPS 的项目较少，而这正是 v3 进步最大的地方。另外，v1 在测试集上本身就比在 dev 集上表现好（log 误差绝对值中位数 0.393 对 0.476）。

结论。 在全集、dev 和测试集上，v3 的命中率、RMSE、偏差和一致性都是最好的。但它相对 baseline 在典型误差上的优势很小，在 held-out 集上没有得到统计上的确认。要定论，需要更大的测试集或外部数据集。

---

10. Feature 研究：模型需要哪些输入？

问题。 baseline 分析表明，误差来自构造和材料的选择，而这些在输入里都没有描述（第 5.1 节）。那么模型是否需要全部 48 个 feature，还是早期设计阶段的信息就够了？这正是课程团队建议的 feature 研究 iteration：比较全部输入和几组较小、与围护相关的子集。

设计。 prompt v3 保持不变，楼、种子、分组、模型（Opus 5.5）和 effort（medium）都和之前一样，只改 feature 列表，feature 说明表也随之筛选。每个子集都保留三个楼面面积字段，因为任务的单位需要用它们来定义。为了控制 token 用量，每个条件只跑一轮（第 **0** 轮），再和 v3 全部 48 个 feature 的第 0 轮逐栋配对比较（`analysis/feature_study.py`，`analysis/feature_study.md`）。

条件	**Feature** 数	内容
all（= v3）	48	`buildings_metadata_LLM.xlsx` 的全部列
early	39	去掉 LCA 事后字段（`lca_*`）和 `mass_total`，只保留设计阶段已知的信息
env	15	气候区、州、用途、项目类型、楼面面积、层数、高度、围护面积、WWR、墙体和屋面 R 值、结构类型、IBC 建造类型
min	10	气候区、用途、项目类型、楼面面积、层数、WWR、墙体和屋面 R 值（对应 proposal 6.1）
no-lca	40	去掉 8 个 `lca_*` 字段
no-mass	47	去掉 `mass_total`

`mass_total` 是参考 LCA 自身材料清单的质量总和（A–C 阶段），早期设计阶段无从得知，而且部分包含了答案。它和真实值的相关是 0.53，v2 和 v3 也曾建议用它来判断改造项目。

其余 7 组 leave-one-group-out 消融（地点、规范年份、用途类型、规模、几何、热工、结构）已经准备好（`FEATURE_SETS`），但为了控制 token 用量中止了。`no-geometry` 有 50 个答案，未纳入分析。

结果（第 **0** 轮，全部 **292** 栋；与 **"all"** 配对）。

条件	**Feature** 数	**±20%** 命中率	**log** 误差绝对值中位数	估算/真实（几何平均）	**RMSE**	相对 **all** 的 **log** 误差变化	**Wilcoxon p**	**McNemar p**
all	48	24.3%	0.461	0.86	77.8	–	–	–
early	39	21.6%	0.462	0.88	81.2	+0.001	0.13	0.30
env	15	19.9%	0.463	0.93	80.6	+0.001	0.33	0.085
min	10	**25.3%**	0.476	0.81	**77.3**	+0.015	0.81	0.83
no-lca	40	**25.3%**	**0.441**	0.90	78.6	−0.020	0.57	0.77
no-mass	47	22.6%	0.452	0.85	79.2	−0.009	0.92	0.56

测试集（88 栋）上的情况一样：min 的命中率为 30.7%，all 为 28.4%，log 误差的差异都不显著。测试集上有两处命中率下降，early −8.0 个百分点（$p = 0.065$）和 env −10.2 个百分点（$p = 0.049$），但考虑到多重比较（5 个条件 × 3 个切分），都不能算显著，而且两者的 log 误差没有差别（$p = 0.08$ 和 0.11）。

噪音有多大？ 同一个 prompt 再跑一次，结果的变化和换 feature 集差不多大。v3 三轮各自的命中率分别是 24.3% / 24.3% / 22.3%，log 误差绝对值中位数分别是 0.461 / 0.436 / 0.454，波动 0.025；v1 的对应波动是 3.4 个百分点和 0.048。上面所有 feature 集之间的差异，都落在这个轮次间的波动范围以内（`analysis/figures/feature_study.png`）。

结论。

1. **10** 个早期设计输入和全部 **48** 个一样好。 气候区、用途、项目类型、楼面面积、层数、WWR 和 R 值这几项，准确率就和全部 feature 一样，其余 38 个 feature 没有可测的贡献。这与第 5.1 节一致：缺的是构造信息，任何子集都不提供。对于 proposal 的问题，这是最实用的结果：在方案设计阶段用 LLM 估算，只需要设计师手上已有的信息。
2. 模型不依赖可能泄露答案的字段。 去掉 `mass_total` 或全部 LCA 事后字段，估算都没有变差，no-lca 甚至略好。所以 v1–v3 的结果并不是靠那些编码了参考 LCA 的 feature 撑起来的。
3. **Prompt** 内容比 **feature** 选择重要得多。 从 v2 到 v3，log 误差绝对值中位数变化 0.137，命中率变化 10 个百分点（第 8.1 节）；而任何 feature 集带来的变化都不超过 0.020 和 4.5 个百分点。

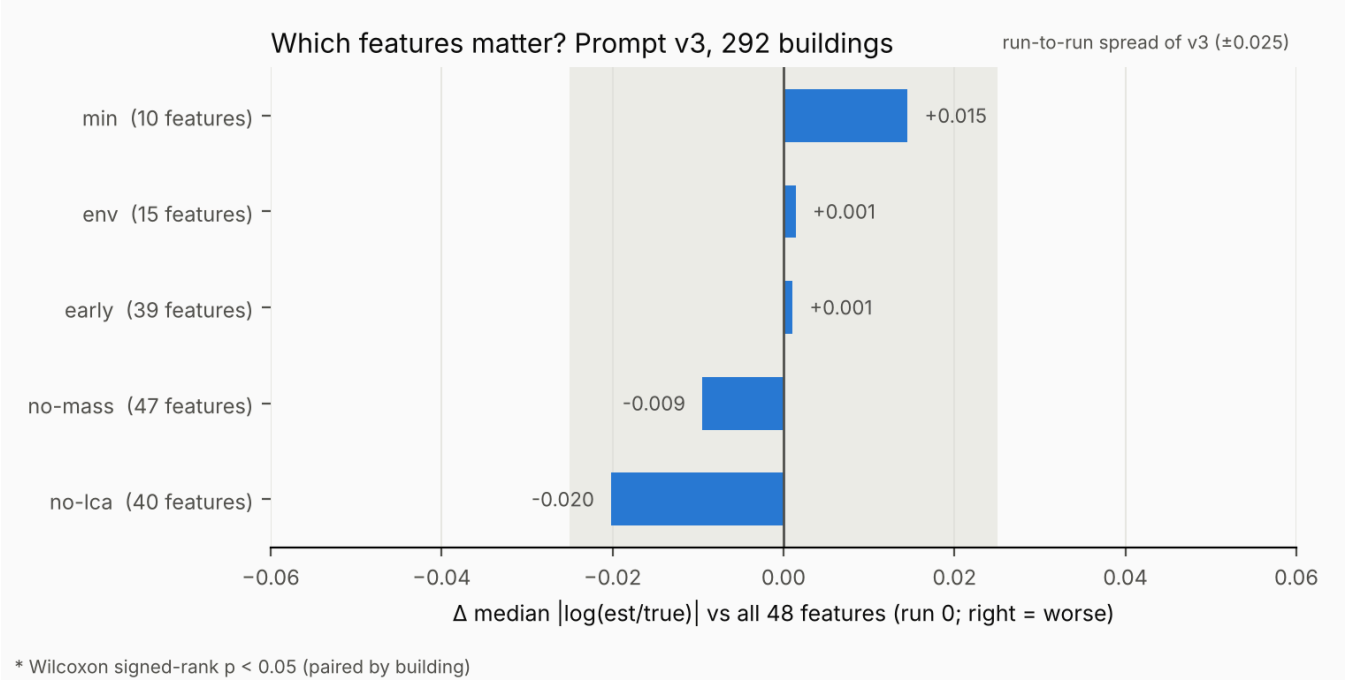


图 10.1：各 feature 集相对全部 48 个 feature 的差异，灰带为轮次间波动

11. 对 LEED v5 的意义

LEED v5 把隐含碳纳入了评分体系：

- 先决条件 **MRp2**（**Quantify and Assess Embodied Carbon**）：量化主要建筑构件（包括外围护结构）的隐含碳，并找出最大的几个热点。
- 得分项 **MRc2**（**Reduce Embodied Carbon**）：奖励减碳。可以用整楼 LCA 与基准方案比较（Option 1），也可以用 EPD 证明产品层面的减碳（Option 2）。

图 11.1 是我们讨论后修改的流程图（初稿为组内的 "Building Envelope LCA and LEED Goals"）。主要修改有三处：

- 在生命周期中标出研究边界：本研究只覆盖 A1–A3，A4–A5、B1–B5、C1–C4/D 标为范围外；
- 加入两条估算路线：参考 LCA 和 LLM 估算（prompt v3），二者都产出 enclosure A1–A3 结果；
- 把右侧的 "LEED goals" 具体化为 LEED v5 的 MRp2 → MRc2 → 检查贡献与证据缺口，最后得到推荐的围护方案，以及它的预计 LEED 贡献和仍缺的文档/数据。

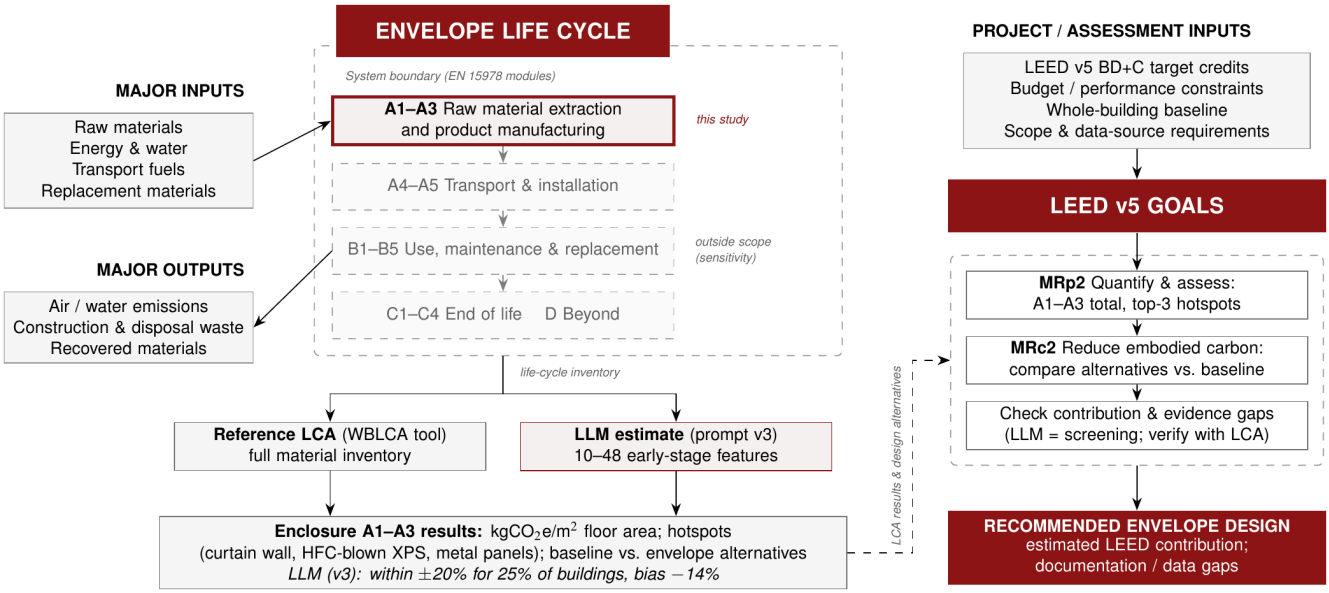


图 11.1：建筑外围护 LCA 与 LEED v5 目标（由初稿修改）

MRp2：适合做热点筛查。 方案设计阶段还没有材料清单，而这个先决条件的目的就是把注意力引向最大的排放来源。v3 的估算适合这个用途：

- 偏差小，整体为 −14%，没有 XPS 的建筑基本无偏；
- 模型的推理会点出数据中真正主导 enclosure 碳排的构件：铝幕墙和铝框、保温类型（HFC-XPS）、金属板和玻璃。

热点一致性的检验（`analysis/hotspot_agreement.py`）。回答是文字，没有结构化的热点列表，所以用一个代理指标：

- 参考热点：每栋楼 enclosure A1–A3 中最大的 3 个材料类别（共 11 个设计层面的类别）；
- 模型热点：回答里提到的类别（关键词匹配）。

不含 10 个不完整的参考：

条件	提到第 **1** 热点	前 **3** 召回率	随机提到同样多类别	每个回答提到的类别数	精确率
固定猜"典型楼"（保温、玻璃、铝）	71.6%	61.1%	27.3%	3.0	60.4%
v1	81.4%	77.1%	51.4%	5.7	42.0%
v2	93.3%	89.7%	67.5%	7.4	36.9%
v3	94.6%	89.7%	60.5%	6.7	41.1%

- 回答是针对具体楼的：第 1 热点不属于常见三类的 80 栋楼里，v3 有 82.1% 提到了第 1 热点，而固定猜典型楼是 0%。
- 但回答不是排好序的前 **3**：平均提到 6.7 个类别，精确率（41%）低于固定猜测（60%）。要用于 MRp2，prompt 应该明确要求按大小列出前 3 个热点。

MRc2：证明减碳所需的精度，**LLM** 达不到。 得分取决于相对基准的减碳百分比，而 v3 的误差是：

- 轮次间 CV 12.5%；
- 绝对误差中位数约 35–40%；
- 只有四分之一的建筑落在 ±20% 以内。

这些误差和项目通常申报的减碳幅度一样大，甚至更大。所以对单栋建筑，LLM 的绝对估算不能用来证明达到得分要求。更有希望的用法是配对比较：对同一栋楼、用同一个 prompt 比较不同围护方案，共同的偏差可以部分抵消。这一点本研究没有测试，申报时仍需要正式 LCA。

Option 1：围护的减碳会被稀释。 在本数据集中，enclosure 的中位数只占整楼 A–C 隐含碳的 19%。围护减碳 30%，在整楼层面只相当于约 6%。单靠围护很难达到整楼减碳目标，围护决策和结构一起考虑时最有价值。在 Option 2 的产品路径中，HFC 发泡 XPS、铝型材、夹芯金属板这类高碳产品，不同 EPD 之间的差距最大（附录 A 的 v3 参考表）。

让早期估算和 **LEED** 基准更可预测的三条建议：

1. 方案阶段就报告构造类型；
2. 写明 LCA 工具默认使用的保温和铝材数据集。仅 HFC-XPS 这一个建模习惯，就影响了我们估算偏差的一半左右；
3. 标记缺少构件组的清单。本数据集中 10 个不完整的参考 LCA，会扭曲任何以它们为基础的基准。

---

12. 局限与下一步

- 缺少构造信息。 没有任何 feature 描述外墙构造，所以不论 prompt 怎么写，准确率都有上限。最有希望的改进是按 proposal（6.1 节）原本的设想，把构造类型加入输入。
- **subagent** 不等于单独的 **API** 调用。 同一个任务文件里的回答共享上下文，独立性不如单独的 API 调用。v3 第 2 轮中有 162 栋是在容器重启后由续跑任务回答的（第 8.1 节）。
- **Held-out** 切分是事后才定的。 只用 dev 集的复现（第 9 节）表明，prompt 的设计不依赖测试集的楼。但要完全排除过拟合，只有用一个从未拿来检验过 prompt 的数据集才行。
- 统计功效。 3 轮运行下，v3 相对 v1 的提升在全部 292 栋上只是接近显著（McNemar $p = 0.085$），在 88 栋测试集上不显著（$p = 0.41$）。增加每栋楼的轮数或增加楼的数量，才能定论。
- **Feature** 研究只跑了一轮。 每个 feature 条件只跑了一次，9 组 leave-one-group-out 消融中有 7 组为控制 token 用量而中止。"feature 集没有影响"这个结论，依据的是落在轮次波动范围以内的差异；它是一个零结果，不能证明这些 feature 无关紧要。
- 功能单位。 结果是每 m^2 楼面面积，而不是每 m^2 外墙；enclosure 还包括窗、门和屋面。
- **Ground truth** 的质量。 质量参差不齐：有 10 个项目被标记为不完整，各工具使用的数据年代也不同（HFC XPS）。
- **LEED** 分析不完整。 热点一致性用的是基于提及的代理指标，没有计算 MRc2 得分档的一致性。
- 文献条件只跑一轮。 只用了 4 份截断到 30k 字符的文献，换别的文献结果可能不同。
- 依赖模型。 结果取决于所用的模型及其版本（Claude Opus 5.5，effort medium）。
- 下一步：
    - 在外部数据集或新的项目集上评估最终 prompt（例如把 CarbEnMats/GBDB 的 enclosure 字段映射到本研究的 feature 集）；

- 加入构造类型的输入（外饰面、保温类型、玻璃系统），也就是 feature 研究显示缺失的信息；
- 完成其余的 leave-one-group-out 消融（`experiment_config.py` 中的 `FEATURE_SETS`，已准备好）；
- 用 CLF 材料基准和 EPD 测试领域知识上下文；
- 按 proposal 的协议扩展到每栋楼 10 轮（种子 1003–1009）。

附录 A. Prompt

Generated by `report/make_prompt_appendix.py` from `experiment_config.py`.

Each request is: system prompt, then the shared context (identical for every building), then the building block (its features, followed by the task text). In the subagent runs, one task file holds the shared context once and 48–49 building blocks.

A. System prompt

```
You are a building LCA expert.
```

B. Shared context (same in v1, v2 and v3)

The glossary has one line per feature in `references/data_glossary_LLM.xlsx`.

```
Forget the information from previous sessions and calculate everything from the beginning.

data_glossary_LLM contains feature names and descriptions for the data:

- project_index: Unique project index number
- site_country: Country where the project is located
- site_region: Region where the project is located. Based on the 2019 National Ready Mix Concrete
Association regions.
- site_state_province: State or province where the project is located.
- site_clim_zone: Climate Zone where the project is located per respective energy code of country.
- bldg_proj_type: Type of construction which details whether the project is new or a type of modification
to an existing building.
- bldg_compl_year: Year of project's actual construction completion, certificate of occupancy, or
anticipated project completion year.
- bldg_code_year: Corresponding year of the international building code (IBC) or other equivalent the
project complied with.
- bldg_energy_code_year: Corresponding year of the international energy conservation code (IECC) or other
equivalent the project complied with.
- bldg_ibc_type: Type of construction per IBC.
- bldg_park_type: Type of attached/integrated parking structure or "parkade".
- bldg_cfa [m2]: Total constructed floor area (CFA) which includes the gross internal floor area (GFA) of
the building and the gross floor area of any attached/integrated parking components.
- bldg_gfa [m2]: Total gross internal floor area (GFA) of the building.
- bldg_parking_gfa [m2]: The total horizontal area occupied by any attached/integrated parking components.
- bldg_added_gfa [m2]: The total horizontal area where new floor area was added to an existing building
(i.e., the floor area of an addition).
- bldg_renovated_gfa [m2]: The total horizontal area where the existing building was renovated.
- bldg_prim_use: Primary classification of the building by principal activity
- bldg_sec_use: Secondary classification of building by principal activity.
- bldg_occupants: Total building occupancy as derived from building code
```

- bldg_res_units: Total number of residential units in the building
- bldg_stories_above: Binned categorization of the number of stories above finished ground level.
- bldg_stories_below: Binned categorization of the number of stories below finished ground level.
- bldg_height [m]: Binned categorization of the total height of the building above finished ground level.
- bldg_therm_env_area [m2]: Total area of the building's thermal envelope.
- bldg_wwr: The ratio of total vertical fenestration area to total above-grade wall area
- bldg_rval_walls: Average nominal R-value of building's above-grade walls.
- bldg_rval_roofs: Average nominal R-value of building's roofs.
- str_seis_site_cls: Classification of the site for seismic design based on its soil and engineering properties.
- str_sdc: Categorization of required seismic design based on risk category and site location.
- str_wind_speed [m/s]: Ultimate wind speed used for ultimate wind design based on location.
- str_prim_horiz_sys: Type of primary horizontal gravity system. Structural floor construction system that supports at least ⅔ of the combined floor and roof area of the superstructure.
- str_prim_vert_sys: Type of primary vertical gravity system. System that transfers gravity loads to the foundation of the building.
- str_lat_sys: Type of lateral system that resists lateral loads of the building.
- str_podium: Designation for whether the project is a podium building – a building with two distinct zones with two different structural materials and systems
- str_sec_horiz_sys: The horizontal gravity system (as defined in Primary Horizontal Gravity System) for the podium portion of the building.
- str_sec_vert_sys: The vertical gravity system (as defined in Primary Vertical Gravity System) for the podium portion of the building
- str_grid_long [m]: Average center to center spacing of longer typical project column grid.
- str_grid_short [m]: Average center to center spacing of shorter typical project column grid.
- str_fdn_type: Type of foundation used to support gravity and lateral loads of project.
- str_sys_summary: Simplified summary of the buildings primary horizontal, vertical, and lateral system.
- lca_assessment_year: Year the LCA was performed
- lca_design_phase: The design phase of the project when the LCA was performed
- lca_RSP [years]: Reference study period for the LCA
- lca_software: Software tool used for the LCA
- lca_purp_of_assessment: Primary reason the LCA was undertaken.
- lca_phys_scope: The physical scope (building elements) included in the assessment.
- lca_ec_reductions: Yes/No designation to indicate if the WBLCA results reflect efforts by the design or construction team to reduce the embodied carbon of the project during design, procurement, and/or construction of the building.
- lca_ec_reduction_percent: Approximate percent reduction in embodied carbon of the building compared to a baseline model, if applicable.
- mass_total [kg]: Total mass of project. Sum of the project's total mass (inv_mass) for life cycle stages A-C
- stored_carbon_total [kg CO_2e]: Total stored carbon of project. Sum of the project's total stored carbon (inv_stored_carbon) for life cycle stages A1-A3
- gwp_a_to_c [kg CO_2e]: Sum of the project's total global warming potential (gwp) for life cycle stages A-C
- ap_a_to_c [kg SO_2e]: Sum of the project's total acidification potential (ap) for life cycle stages A-C
- ep_a_to_c [kg Ne]: Sum of the project's total eutrophication potential (ep) for life cycle stages A-C
- sfp_a_to_c [kg O3e]: Sum of the project's total smog formation potential (sfp) for life cycle stages A-C
- odp_a_to_c [kg CFC-11e]: Sum of the project's total ozone depletion potential (odp) for life cycle stages A-C
- nred_a_to_c [MJ]: Sum of the project's total non-renewable energy demand (nred) for life cycle stages A-C
- mui_total_GFA [kg/m3]: Total material use intensity. Sum of the project's total material use intensity (mui_gfa) over the full RSP normailized by GFA for new construction projects. Includes material replacements from module B.
- eci_a_to_c_GFA [kgCO_2e/m2]: Embodied carbon intensity. Sum of the project's total global warming potential (gwp) for life cycle stages A-C normalized by GFA for new construction projects.
- epi_a_to_c_GFA [kgNe/m2]: Eutrophication potential intensity. Sum of the project's total eutrophication potential (ep) for life cycle stages A-C normalized by GFA for new construction projects.
- api_a_to_c_GFA [kgSO_2e/m2]: Acidification potential intensity. Sum of the project's total acidification potential (ap) for life cycle stages A-C normalized by GFA for new construction projects.
- sfpi_a_to_c_GFA [kgO3e/m2]: Smog formation potential intensity. Sum of the project's total smog formation potential (sfp) for life cycle stages A-C normalized by GFA for new construction projects.
- odpi_a_to_c_GFA [kgCFC11e/m2]: Ozone depletion potential intensity. Sum of the project's total ozone

depletion potential (odp) for life cycle stages A-C normalized by GFA for new construction projects.
- nredi_a_to_c_GFA [MJ/m2]: Non-renewable energy demand intensity. Sum of the project's total non-renewable energy depletion intensity (nredi) for life cycle stages A-C normalized by GFA for new construction projects.
- mui_total_CFA [kg/m2]: Total material use intensity. Sum of the project's total material use intensity (mui_cfa) over the full RSP normailized by CFA for new construction projects. Includes material replacements from module B.
- eci_a_to_c_CFA [kgCO_2e/m2]: Embodied carbon intensity. Sum of the project's total global warming potential (gwp) for life cycle stages A-C normalized by CFA for new construction projects.
- epi_a_to_c_CFA [kgNe/m2]: Eutrophication potential intensity. Sum of the project's total eutrophication potential (ep) for life cycle stages A-C normalized by CFA for new construction projects.
- api_a_to_c_CFA [kgSO_2e/m2]: Acidification potential intensity. Sum of the project's total acidification potential (ap) for life cycle stages A-C normalized by CFA for new construction projects.
- sfpi_a_to_c_CFA [kgO3e/m2]: Smog formation potential intensity. Sum of the project's total smog formation potential (sfp) for life cycle stages A-C normalized by CFA for new construction projects.
- odpi_a_to_c_CFA [kgCFC11e/m2]: Ozone depletion potential intensity. Sum of the project's total ozone depletion potential (odp) for life cycle stages A-C normalized by CFA for new construction projects.
- nredi_a_to_c_CFA [MJ/m2]: Non-renewable energy demand intensity. Sum of the project's total non-renewable energy depletion intensity (nredi) for life cycle stages A-C normalized by CFA for new construction projects.
- ec_per_occupant_a_to_c [
kgCO2e/occupant

]: Embodied carbon per occupant. Sum of the project's total global warming potential (gwp) for life cycle stages A-C normalized by the number of buildings occupants (bldg_occupants).
- ec_per_res_unit_a_to_c [kgCO2e/ unit]: Embodied carbon per residential unit. Summary of the project's total GWP (gwp) for life cycle stages A-C normalized by number of residential units (bldg_res_units).
- nan: nan
- nan: nan
- nan: nan
- nan: nan
- nan: nan
- nan: nan
- nan: nan
- nan: nan
- nan: nan
- nan: nan
- nan [kg]: nan
- nan [kg CO_2e]: nan
- nan [kg CO_2e]: nan
- nan [kg SO_2e]: nan
- nan [kg Ne]: nan
- nan [kg O3e]: nan
- nan [kg CFC-11e]: nan
- nan [MJ]: nan
- nan [kg/m2]: nan
- nan [kg/m2]: nan

Reference the given feature information above. Estimate the embodied carbon of the building enclosure of the building below:

C. Task text v1 (baseline)

Scope: the building enclosure only, i.e. OmniClass "Shell - Enclosure" (exterior walls and cladding, exterior windows, curtain walls and storefronts, exterior doors, roofing, and their insulation). Exclude substructure, superstructure, interior construction and interior finishes. Life cycle stages: A1-A3 only (product stage: raw material supply, transport to the factory, manufacturing). Exclude A4, A5, B, C and D.

Provide a plausible range of the enclosure's A1-A3 embodied carbon in units of kgCO2e per m2 of building floor area (a range, not a single value). For floor area, use bldg_cfa. If bldg_cfa is not provided, use bldg_renovated_gfa + bldg_added_gfa. Briefly state your method and key assumptions.

```
End your answer with exactly one final line in this format and nothing after it:
RANGE_kgCO2e_per_m2: <low> - <high>
(plain numbers only, no units or other text on that line)
```

D. Task text v2

```
Scope. Estimate the embodied carbon of the building enclosure as classified in this dataset (OmniClass
"Shell - Enclosure"), life cycle stages A1-A3 only (raw material supply, transport to the factory,
manufacturing). Exclude A4, A5, B, C and D. The enclosure includes:
- exterior walls as complete assemblies: cladding, backup framing or studs, sheathing, cavity and
continuous insulation, air and vapor barriers, and the interior gypsum layer of exterior walls; structural
exterior walls (concrete, CMU, tilt-up) when they form the wall;
- fenestration: windows, curtain wall, storefront and skylights (frames and glass), and exterior doors;
- the roof assembly above the structural deck: insulation, cover board, membrane or roofing;
- insulation at slab edges, below grade and under slabs that belongs to the thermal envelope.
It excludes foundations, the structural frame, floor and roof decks or slabs, interior partitions and
interior finishes.

Method. Work through these steps and show the key numbers:
1. Areas. If bldg_therm_env_area is given, use it as the total envelope area. Otherwise estimate the roof
area (footprint = floor area / stories above grade), the above-grade wall area (perimeter x height) and
the glazed area (bldg_wwr x wall area), plus any insulated ground-floor or below-grade area. State the
resulting envelope-to-floor-area ratio; single-storey and low-rise buildings often exceed 1.
2. Assemblies. From the climate zone, R-values, building use, structure, region and construction type,
choose the most likely wall, glazing and roof assemblies. Name the insulation type and estimate its
thickness from the R-value.
3. Intensities. Give each component an A1-A3 intensity in kgCO2e per m2 of that component, using values
typical of the North American whole-building LCA tools of the assessment year (Tally, One Click LCA).
Account for these high-impact materials:
   - XPS insulation made with HFC blowing agents is common in these tools and carries roughly ten times or
more the GWP of mineral wool, fiberglass or polyiso per unit of thermal resistance, so a thick XPS layer
(for example roof or below-grade insulation in cold climates) can dominate the enclosure total.
   - Aluminum is carbon-intensive per kg (curtain wall and storefront framing, window frames, metal
panels, ACM). Aluminum-framed curtain wall is about 100-200 kgCO2e per m2 of facade, and fully glazed
curtain wall facades are among the highest-carbon enclosures.
   - Insulated glass units, precast concrete panels and masonry are also significant.
4. Total. Sum the components, divide by the floor area, and give a range that reflects your uncertainty
about the assemblies. Do not pull the estimate toward a typical building: metal-clad, curtain-wall or
thickly insulated enclosures can exceed 200 kgCO2e per m2 of floor area, and projects with little new
enclosure work can fall below 10.
5. Renovations. For renovations and tenant improvements, count only new enclosure materials. Use
bldg_proj_type, lca_phys_scope and mass_total per floor area to judge how much new envelope work was done.
Major renovations often include new windows, cladding or roofing, and a high mass_total per floor area
indicates substantial new material.

Floor area: use bldg_cfa. If bldg_cfa is not provided, use bldg_renovated_gfa + bldg_added_gfa.

End your answer with exactly two final lines in this format and nothing after them:
BEST_kgCO2e_per_m2: <value>
RANGE_kgCO2e_per_m2: <low> - <high>
(plain numbers only, no units or other text on these lines)
```

E. Task text v3 (final prompt)

Reference values come from `references/envelope_intensities_sources.md` (sources and conversions listed there).

Scope. Estimate the embodied carbon of the building enclosure as classified in this dataset (OmniClass "Shell - Enclosure"), life cycle stages A1-A3 only (raw material supply, transport to the factory, manufacturing). Exclude A4, A5, B, C and D. The enclosure includes:
- exterior walls as complete assemblies: cladding, backup framing or studs, sheathing, cavity and continuous insulation, air and vapor barriers, and the interior gypsum layer of exterior walls; structural exterior walls (concrete, CMU, tilt-up) when they form the wall;
- fenestration: windows, curtain wall, storefront and skylights (frames and glass), and exterior doors;
- the roof assembly above the structural deck: insulation, cover board, membrane or roofing;
- insulation at slab edges, below grade and under slabs that belongs to the thermal envelope.
It excludes foundations, the structural frame, floor and roof decks or slabs, interior partitions and interior finishes.

Method. Work through these steps and show the key numbers:
1. Areas. If bldg_therm_env_area is given, use it as the total envelope area. Otherwise estimate the roof area (footprint = floor area / stories above grade), the above-grade wall area (perimeter x height) and the glazed area (bldg_wwr x wall area), plus any insulated ground-floor or below-grade area. State the resulting envelope-to-floor-area ratio; single-storey and low-rise buildings often exceed 1.
2. Assemblies. From the climate zone, R-values, building use, structure, region and construction type, choose the most likely wall, glazing and roof assemblies, and name the insulation type and thickness. Whole-building LCA models from this period (Tally, One Click LCA) often model roof and below-grade insulation as XPS made with HFC blowing agents. When the insulation type is not known, include that case in your range, especially in colder climates where the insulation is thick.
3. Intensities. Give each component an A1-A3 intensity in kgCO2e per m2 of that component. Use these reference values from EPDs and industry baselines (A1-A3, per m2 of component):
   Opaque walls (per m2 of wall, complete assembly):
   - steel stud + metal panel or ACM rainscreen: 70-110
   - steel stud + brick veneer: 90-120; brick veneer on CMU backup: 135-165
   - steel stud + EIFS: about 50; steel stud + fiber cement or stucco: 45-80
   - wood stud + vinyl or wood siding: 25-45; wood stud + brick or stone veneer: 60-100
   - insulated metal panel: newer products 27-72; legacy polyurethane (HFC) panels about 107 (2 in) to 274 (6 in)
   - precast concrete sandwich panel: 90-165; architectural precast with backup wall: 80-130
   - tilt-up concrete with interior insulation and gypsum: 80-125
   - curtain-wall spandrel: 75-140
   Fenestration (per m2 of unit, frame and glass):
   - aluminum stick curtain wall: 120-150; aluminum unitized curtain wall: 150-210
   - aluminum storefront: 140-155; aluminum window wall: 170-180; aluminum windows: 95-140
   - vinyl windows: 40-90; fiberglass windows: 75-145
   Roof above the deck (per m2 of roof, about R-25 to R-30, with membrane and cover board):
   - polyiso: 20-28; mineral wool board: 35-55; low-GWP XPS: 28-40; metal standing seam over polyiso: 27-40
   - XPS with HFC blowing agent: 85-110 when only product-stage emissions are counted, and up to 335-410 when the blowing-agent emissions are booked with the product, as some LCA tools do
   - insulated metal roof panel: 27-72 for newer products, about 190 for a legacy 4 in panel
   Insulation per m2 at RSI 1 (R-5.7): polyiso 2-4; EPS 2.5; mineral wool board 7-8; fiberglass batt about 1; closed-cell spray foam 3-5 (HFO) or 20-36 (HFC); XPS 4-11 (low-GWP), about 18 (HFC, product stage only) or 58-99 (HFC, with blowing-agent emissions)
   Aluminum: about 6-13 kgCO2e per kg for North American extrusions; generic global aluminum data in LCA tools is about 16
Complete assemblies include framing, attachments, sheathing, barriers, sealants, flashing and trim, which early-stage take-offs tend to leave out; do not go below the low end of these ranges unless the assembly is clearly minimal.
4. Check. Convert your total to kgCO2e per m2 of envelope area and check that it is consistent with the reference values above. For new construction with conventional walls and 30-40% glazing, a blended value below about 50 kgCO2e per m2 of envelope usually means that a component, the aluminum and glazing content, or a high-carbon insulation option is missing; revisit those before you finalize.
5. Total. Divide the enclosure total by the floor area. Give a range that reflects your uncertainty about the assemblies, including the higher-carbon alternatives that are plausible for this building. Do not pull the estimate toward a typical building: metal-clad, curtain-wall or thickly insulated enclosures can exceed 200 kgCO2e per m2 of floor area, and projects with little new enclosure work can fall below 10.
6. Renovations. For renovations and tenant improvements the LCA covers only the new work, but that work often includes substantial new envelope elements (re-cladding, new curtain wall or windows, re-roofing).

```
Do not assume the existing envelope is kept unless the data indicates it. Use bldg_proj_type,
lca_phys_scope and mass_total per floor area as evidence of how much new material was installed.

Floor area: use bldg_cfa. If bldg_cfa is not provided, use bldg_renovated_gfa + bldg_added_gfa.

End your answer with exactly one final line in this format and nothing after it:
RANGE_kgCO2e_per_m2: <low> - <high>
(plain numbers only, no units or other text on that line)
```

F. Example building block, v3 (project-225)

```
site_country: United States
site_region: Eastern
site_clim_zone: Zone 5A (Cool Humid)
bldg_code_year: 2015
bldg_energy_code_year: 2009
bldg_proj_type: New Construction
bldg_ibc_type: Type I-A
bldg_park_type: No Parking
bldg_cfa: 25000
bldg_gfa: 25000
bldg_prim_use: Healthcare
bldg_occupants: 2062
bldg_stories_above: 6 to 10
bldg_stories_below: 2
bldg_height: 22.6-30 m
bldg_therm_env_area: 12133.1318
bldg_wwr: 0.4
str_seis_site_cls: D
str_sdc: C
str_wind_speed: 56.77408
str_prim_horiz_sys: Steel: Frame + concrete on metal deck
str_prim_vert_sys: Steel: Columns
str_lat_sys: Steel: Moment frames
str_podium: Primary system defined above is on a podium
str_sec_horiz_sys: Concrete: Non-PT framing
str_sec_vert_sys: Concrete: CIP
str_grid_long: 10.668
str_grid_short: 10.668
str_fdn_type: Deep foundation > 50' (15m)
str_sys_summary: Steel
lca_assessment_year: 2023
lca_design_phase: Construction
lca_rsp: 60
lca_software: Tally LCA
lca_purp_of_assessment: Voluntary: Internal Benchmarking
lca_phys_scope: BSECF
lca_ec_reductions: Yes
lca_ec_reduction_percent: 0.106
mass_total: 39350375.72180476

Scope. Estimate the embodied carbon of the building enclosure as classified in this dataset (OmniClass
"Shell - Enclosure"), life cycle stages A1-A3 only (raw material supply, transport to the factory,
manufacturing). Exclude A4, A5, B, C and D. The enclosure includes:
- exterior walls as complete assemblies: cladding, backup framing or studs, sheathing, cavity and
continuous insulation, air and vapor barriers, and the interior gypsum layer of exterior walls; structural
exterior walls (concrete, CMU, tilt-up) when they form the wall;
- fenestration: windows, curtain wall, storefront and skylights (frames and glass), and exterior doors;
- the roof assembly above the structural deck: insulation, cover board, membrane or roofing;
- insulation at slab edges, below grade and under slabs that belongs to the thermal envelope.
It excludes foundations, the structural frame, floor and roof decks or slabs, interior partitions and
```

```
interior finishes.

Method. Work through these steps and show the key numbers:
1. Areas. If bldg_therm_env_area is given, use it as the total envelope area. Otherwise estimate the roof
area (footprint = floor area / stories above grade), the above-grade wall area (perimeter x height) and
the glazed area (bldg_wwr x wall area), plus any insulated ground-floor or below-grade area. State the
resulting envelope-to-floor-area ratio; single-storey and low-rise buildings often exceed 1.
2. Assemblies. From the climate zone, R-values, building use, structure, region and construction type,
choose the most likely wall, glazing and roof assemblies, and name the insulation type and thickness.
Whole-building LCA models from this period (Tally, One Click LCA) often model roof and below-grade
insulation as XPS made with HFC blowing agents. When the insulation type is not known, include that case
in your range, especially in colder climates where the insulation is thick.
3. Intensities. Give each component an A1-A3 intensity in kgCO2e per m2 of that component. Use these
reference values from EPDs and industry baselines (A1-A3, per m2 of component):
   Opaque walls (per m2 of wall, complete assembly):
   - steel stud + metal panel or ACM rainscreen: 70-110
   - steel stud + brick veneer: 90-120; brick veneer on CMU backup: 135-165
   - steel stud + EIFS: about 50; steel stud + fiber cement or stucco: 45-80
   - wood stud + vinyl or wood siding: 25-45; wood stud + brick or stone veneer: 60-100
   - insulated metal panel: newer products 27-72; legacy polyurethane (HFC) panels about 107 (2 in) to 274
(6 in)
   - precast concrete sandwich panel: 90-165; architectural precast with backup wall: 80-130
   - tilt-up concrete with interior insulation and gypsum: 80-125
   - curtain-wall spandrel: 75-140
   Fenestration (per m2 of unit, frame and glass):
   - aluminum stick curtain wall: 120-150; aluminum unitized curtain wall: 150-210
   - aluminum storefront: 140-155; aluminum window wall: 170-180; aluminum windows: 95-140
   - vinyl windows: 40-90; fiberglass windows: 75-145
   Roof above the deck (per m2 of roof, about R-25 to R-30, with membrane and cover board):
   - polyiso: 20-28; mineral wool board: 35-55; low-GWP XPS: 28-40; metal standing seam over polyiso: 27-
40
   - XPS with HFC blowing agent: 85-110 when only product-stage emissions are counted, and up to 335-410
when the blowing-agent emissions are booked with the product, as some LCA tools do
   - insulated metal roof panel: 27-72 for newer products, about 190 for a legacy 4 in panel
   Insulation per m2 at RSI 1 (R-5.7): polyiso 2-4; EPS 2.5; mineral wool board 7-8; fiberglass batt about
1; closed-cell spray foam 3-5 (HFO) or 20-36 (HFC); XPS 4-11 (low-GWP), about 18 (HFC, product stage only)
or 58-99 (HFC, with blowing-agent emissions)
   Aluminum: about 6-13 kgCO2e per kg for North American extrusions; generic global aluminum data in LCA
tools is about 16
Complete assemblies include framing, attachments, sheathing, barriers, sealants, flashing and trim, which
early-stage take-offs tend to leave out; do not go below the low end of these ranges unless the assembly
is clearly minimal.
4. Check. Convert your total to kgCO2e per m2 of envelope area and check that it is consistent with the
reference values above. For new construction with conventional walls and 30-40% glazing, a blended value
below about 50 kgCO2e per m2 of envelope usually means that a component, the aluminum and glazing content,
or a high-carbon insulation option is missing; revisit those before you finalize.
5. Total. Divide the enclosure total by the floor area. Give a range that reflects your uncertainty about
the assemblies, including the higher-carbon alternatives that are plausible for this building. Do not pull
the estimate toward a typical building: metal-clad, curtain-wall or thickly insulated enclosures can
exceed 200 kgCO2e per m2 of floor area, and projects with little new enclosure work can fall below 10.
6. Renovations. For renovations and tenant improvements the LCA covers only the new work, but that work
often includes substantial new envelope elements (re-cladding, new curtain wall or windows, re-roofing).
Do not assume the existing envelope is kept unless the data indicates it. Use bldg_proj_type,
lca_phys_scope and mass_total per floor area as evidence of how much new material was installed.

Floor area: use bldg_cfa. If bldg_cfa is not provided, use bldg_renovated_gfa + bldg_added_gfa.

End your answer with exactly one final line in this format and nothing after it:
RANGE_kgCO2e_per_m2: <low> - <high>
(plain numbers only, no units or other text on that line)
```

G. Subagent instructions (template)

Rendered per task by `subagent_runs.py prepare` into `results/<run>/subagent/tasks/<task>.instructions.txt`.

```
You are the language model being tested in a building life-cycle-assessment (LCA) experiment for a
university course project. Your job is to answer a set of estimation prompts using only your own
knowledge.

Input file: {task_file}
It is about {n_lines:,} lines, so read all of it with the Read tool, using offset/limit to page past line
2,000. It contains a System line, a shared context (a glossary of the feature names), and {n_buildings}
building sections. Each section starts with a line like `===== KEY: {example_key} =====`, followed by the
building's features and the question.

Rules. Breaking any of these invalidates the experiment:
- Read only that one task file. Do not open, list or search any other file or folder (especially nothing
under results/, GWP-calculation/ or references/). Do not use web search or web fetch, and do not run code
or shell commands. The only tools you may use are Read (on the task file) and Write (for your answer
files).
- Treat each building as a separate, independent request, as if you were seeing it alone. Do not compare
buildings, rank them, or adjust one estimate because of another.
- Follow each building's prompt exactly: {answer_length}, then end with {final_lines} containing plain
numbers only.

Output: write your answers in parts of about 10 buildings each, using one new file per part and never
overwriting an earlier part:
{answers_prefix}_part-1.md, then _part-2.md, and so on.
Inside each part file, every answer starts with its key line copied exactly from the task file, followed
by the answer text, for example:

===== KEY: {example_key} =====
<answer>
{example_final}

Answer all {n_buildings} buildings, in the order they appear in the task file, with the key lines copied
exactly.

When you are finished, reply with exactly one line: `done: <number of answers written> answers in <number
of parts> parts`. Do not include the answers themselves in your reply.
```

附录 B. 复现

复现命令与英文版 `report.md` 附录 B 相同，依次运行：

1. 生成 ground truth：`python GWP-calculation/sum_gwp.py`
2. 生成材料分解和数据质量标记：`python GWP-calculation/enclosure_breakdown.py`
3. 准备任务文件：`python subagent_runs.py prepare --run-name <run> --runs 3 --model-label "claude-opus-5-5 (Claude Code subagent)" --effort medium`（feature 研究加上 `--feature-set <name> --runs 1`）
4. 每个 `results/<run>/subagent/tasks/*.instructions.txt` 启动一个 Claude Code subagent（Opus，medium），被中断时用 `python subagent_runs.py resume --run-name <run>` 续跑
5. 收集答案：`python subagent_runs.py collect --run-name <run>`

6. 数据清洗和图：`python LLM-data-cleaning.py <run>`、`python make_fig1_bands.py <run>`、`python summarize_run.py <run>`
7. 误差分析：`python analysis/error_analysis.py [--split dev|test] <run1> <run2> ...`
8. Held-out 切分和配对比较：`python analysis/make_split.py`、`python analysis/compare_runs.py <run1> <run2> ...`
9. Feature 研究：`python analysis/feature_study.py`
10. 生成 prompt 附录：`python report/make_prompt_appendix.py`